



Lavorare con i dati usando l'IA

Sessione 1 di 3



Chi sono

Federico Rios

- Founder & AI Engineer presso **aidea**
- Docente con **Boolean**
- Ricercatore al **Politecnico di Milano** (fino a poco tempo fa)




Cosa faremo in 3 sessioni

Prenderemo un dataset reale di ricette e costruiremo progressivamente strumenti sempre più potenti.

1. **Sessione 1:** Estrarre dati strutturati da testo grezzo
2. **Sessione 2:** Costruire un sistema di ricerca conversazionale RAG
3. **Sessione 3:** Creare un assistente capace di eseguire azioni

Ogni sessione si basa sulla precedente. Alla fine, saremo passati da testo disordinato a un sistema funzionante basato sull'AI.

Oggi: Sessione 1: partiamo dai dati.



Il dataset



13.500 ricette da Epicurious

Estrate da un popolare sito di ricette, impacchettate su **Kaggle**, disponibili su **Hugging Face**.

Ogni ricetta ha:

Colonna	Esempio
Title	Miso-Butter Roast Chicken With Acorn Squash Panzanella
Ingredients	<code>['1 (3½-4-lb.) whole chicken', '2¾ tsp. kosher salt', ...]</code>
Instructions	Pat chicken dry with paper towels, season all over with...

Tutto qui. Nessuna categoria, nessun tag di cucina, nessuna valutazione di difficoltà, essenzialmente testo grezzo.

Che tipo di ricette?

Da cocktail con 4 ingredienti a nachos con 51 ingredienti.

Ricetta	Ingredienti
Warm Comfort (cocktail)	4
Crispy Salt and Pepper Potatoes	7
Pumpkin Dutch Baby	13
Miso-Butter Roast Chicken	22
Epi's 50-Ingredient Super Bowl Nachos	51

Dati del mondo reale: disordinati, non sempre coerenti, e molti edge cases.

Esploriamolo

(notebook)



Cosa possiamo fare con questi dati?

(senza IA)




Python puro ci porta relativamente lontano

Con solo `ast.literal_eval` , operazioni base sulle stringhe e pandas:

- **Parsing** delle liste di ingredienti in formato stringa in vere liste Python
- **Conteggio** degli ingredienti per ricetta
- **Calcolo di statistiche:** distribuzioni, medie, outlier
- **Ricerca:** trovare ricette che contengono "chicken" o "chocolate"
- **Filtro:** ricette con meno di 5 ingredienti, istruzioni più brevi
- **Ordinamento e classificazione:** ricette più complesse, ricette più semplici

Queste sono tutte operazioni sui **dati così come sono**.



Proviamoci

(notebook)



Cosa non possiamo fare?



Guardiamo una singola stringa di ingredienti

```
'2¾ tsp. kosher salt, divided, plus more'
```

Un essere umano legge questo e sa immediatamente:

- **Quantità:** 2.75
- **Unità:** teaspoon
- **Ingrediente:** kosher salt
- **Note:** divided, plus more

Possiamo scrivere codice per estrarre queste informazioni?



Proviamo con le regex

```
pattern = r'^([\d12341223]+)\s+(tsp|Tbsp|cup|lb|oz)\.?.?\s+(.+)'
```

Funziona per `2¾ tsp. kosher salt`, ma che dire di:

Stringa ingrediente	Problema
<code>Pinch of crushed red pepper flakes</code>	Nessuna quantità numerica
<code>1 (3½-4-lb.) whole chicken</code>	Intervallo tra parentesi
<code>6 Tbsp. unsalted butter, melted, plus 3 Tbsp. room temperature</code>	Due quantità, due stati
<code>One 14-ounce can whole peeled tomatoes</code>	Numero scritto a lettere, unità annidata
<code>Salt and pepper</code>	Nessuna quantità


Ogni caso limite richiede una nuova regola. E ci sono **migliaia** di formati.

Non sono solo gli ingredienti

Cos'altro è nascosto nel testo e non possiamo estrarre facilmente?

- **Tecniche di cottura:** questa ricetta è al forno, alla griglia o saltata in padella?
- **Tipo di cucina:** Italiana? Giapponese? Fusion?
- **Livello di difficoltà:** cena veloce infrasettimanale o progetto di più giorni?
- **Info dietetiche:** è vegetariana? senza glutine?
- **Tempi:** quanto dura ogni passaggio?

Tutte queste informazioni sono *nel* testo. Un essere umano può leggerlo e dirtelo. Ma non c'è una colonna per queste informazioni, e nessuna regex che generalizzi.



Il divario

Cosa può fare il codice

Lavorare con i dati **così come sono**

- Contare, filtrare, ordinare, cercare
- Corrispondenza esatta di stringhe
- Pattern fissi (regex)

Cosa vogliamo davvero

Comprendere il testo ed estrarne il significato

- Analizzare formati variabili
- Categorizzare e classificare
- Dedurre informazioni non esplicitamente dichiarate



E se potessimo semplicemente... chiedere?

(prossimo: slide LLM + notebook)

